Preparação dos dados e diagnóstico de churn

Contribuição de John para o relatório de segmentação da Vitaliza. Versão preparada para revisão e integração pelo grupo.

O que os dados sustentam

Achado	Evidência	Leitura
Alta do churn	5,61% → 6,61% em jan–set	Piora de aproximadamente 1 ponto percentual em períodos equivalentes.
Piora dentro dos planos	Mensal: 9,14% → 10,86% Anual: 2,45% → 3,32%	A mudança de composição para o anual atenua a alta agregada.
Uso anterior associado à saída	2026: 11,18% sem treinos 4,04% com oito ou mais	Sinal para diagnóstico; sem efeito causal demonstrado.
Hipótese técnica a investigar	383 tickets técnicos em maio e 310 em junho/2026	Picos posteriores não explicam, sozinhos, o pico de churn de abril.

Base entregue: 14.753 pagantes no corte, uma linha por usuário. O arquivo para Leonardo contém 17 variáveis candidatas de agrupamento e a chave de integração. Seleção das variáveis, tratamento de ausências, escalas e validação dos clusters pertencem à frente de clusterização.

Escopo: integração, indicadores, diagnóstico e hipóteses. O trabalho ainda não atribui clusters, prevê saída futura, estima uplift ou calcula retorno de contato.

Leitura das taxas: salvo indicação de média mensal simples, o churn de um período é calculado por perdas divididas por exposições usuário-mês. Exposições não são pessoas distintas.

1. Evolução do churn

Em cada mês, o denominador é a população pagante ativa no início; o numerador contém as pessoas dessa população cuja assinatura expirou no mês. Inícios e fins dentro do próprio mês ficam fora dessa taxa.

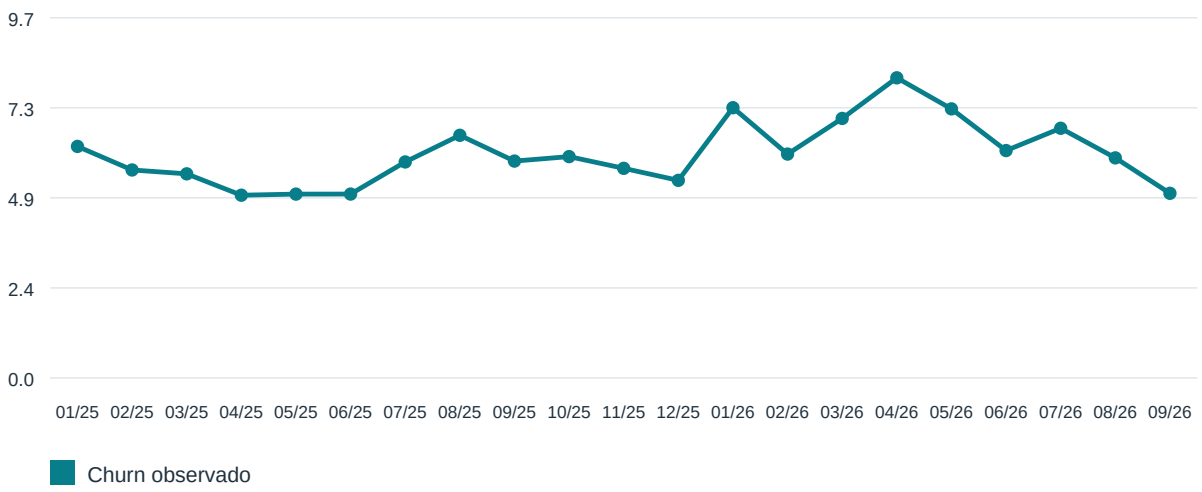

Mês	Ativos no início	Perdas	Churn
2025-01	8.540	534	6,25%
2025-02	9.418	529	5,62%
2025-03	10.014	552	5,51%
2025-04	10.577	522	4,94%
2025-05	10.937	543	4,96%
2025-06	11.317	562	4,97%
2025-07	11.640	679	5,83%
2025-08	11.811	774	6,55%
2025-09	12.020	704	5,86%
2025-10	12.413	742	5,98%
2025-11	12.771	723	5,66%
2025-12	13.023	695	5,34%
2026-01	13.140	959	7,30%
2026-02	13.728	830	6,05%
2026-03	14.111	989	7,01%
2026-04	14.237	1.154	8,11%
2026-05	14.119	1.026	7,27%
2026-06	14.102	866	6,14%
2026-07	14.059	948	6,74%
2026-08	14.032	834	5,94%
2026-09	14.319	714	4,99%

Média mensal simples: **5,62% em 2025** e **6,62% em jan–set/2026**. O pico de abril/2026 foi de 1.154 perdas sobre 14.237 ativos (8,11%). Na comparação jan–set dos dois anos, a taxa ponderada passa de 5,61% para 6,61%.

2. Plano, canal e composição

A piora aparece nos dois planos em meses equivalentes. O anual tem calendário de renovação diferente: sua taxa menor não é uma medida direta de maior satisfação.

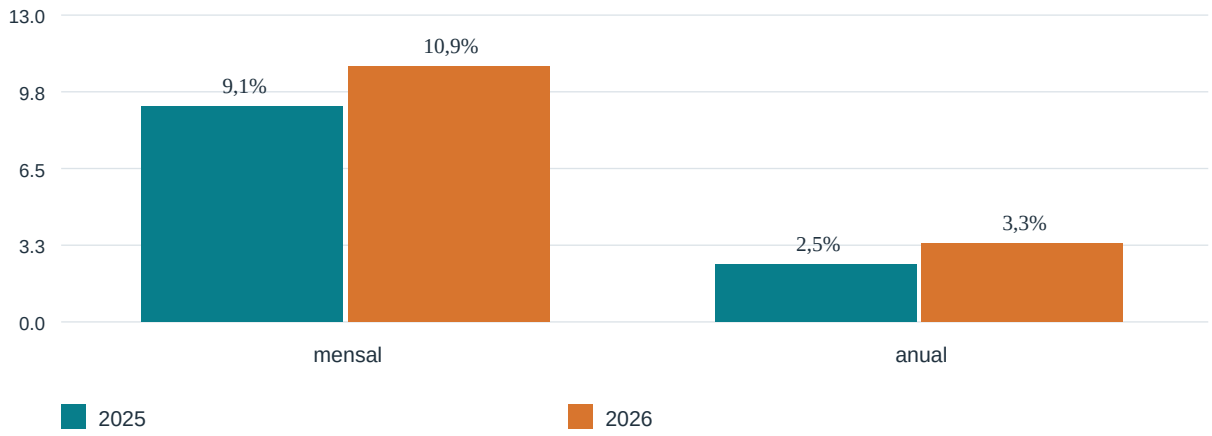

Gráfico acima: janeiro a setembro nos dois anos. Taxas por exposição usuário-mês.

Decomposição da alta de aproximadamente 1,00 p.p.: +1,25 p.p. vêm aritmeticamente da piora das taxas dentro dos planos; –0,25 p.p. vêm da mudança de composição. A participação do anual nas exposições cresce de 52,83% para 56,37%. A decomposição fecha a conta e não identifica causas.

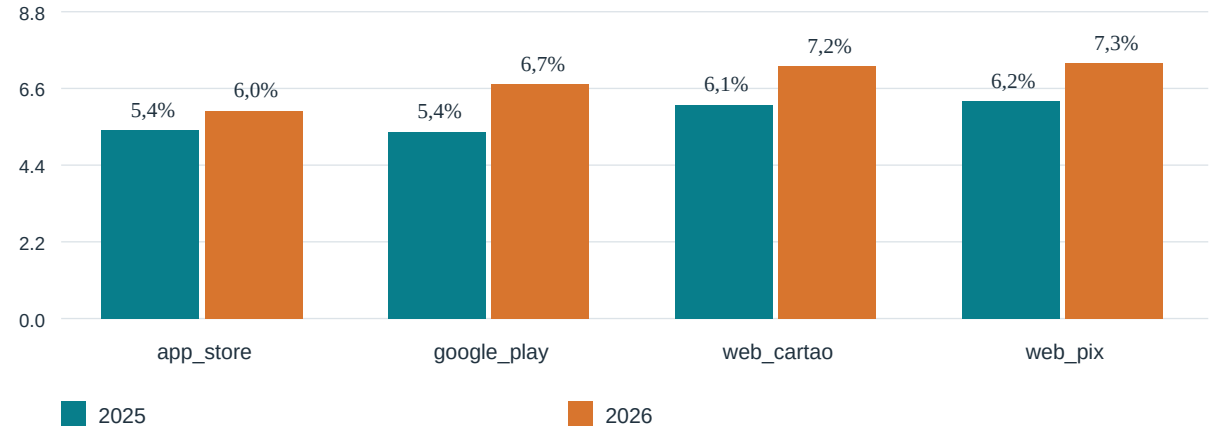

Gráfico de canais: 2025 completo e janeiro–setembro/2026. Em 2026, as taxas vão de 5,96% na App Store a 7,33% no Pix. Canal pode marcar diferenças de plano, público, tempo de casa ou cobrança; a comparação bruta não isola seu efeito.

3. Uso anterior e saída posterior

A comparação usa os treinos do mês anterior, entre pessoas que já eram pagantes no início daquele mês. Isso evita medir como antecedente uma queda de uso produzida pelo próprio cancelamento.

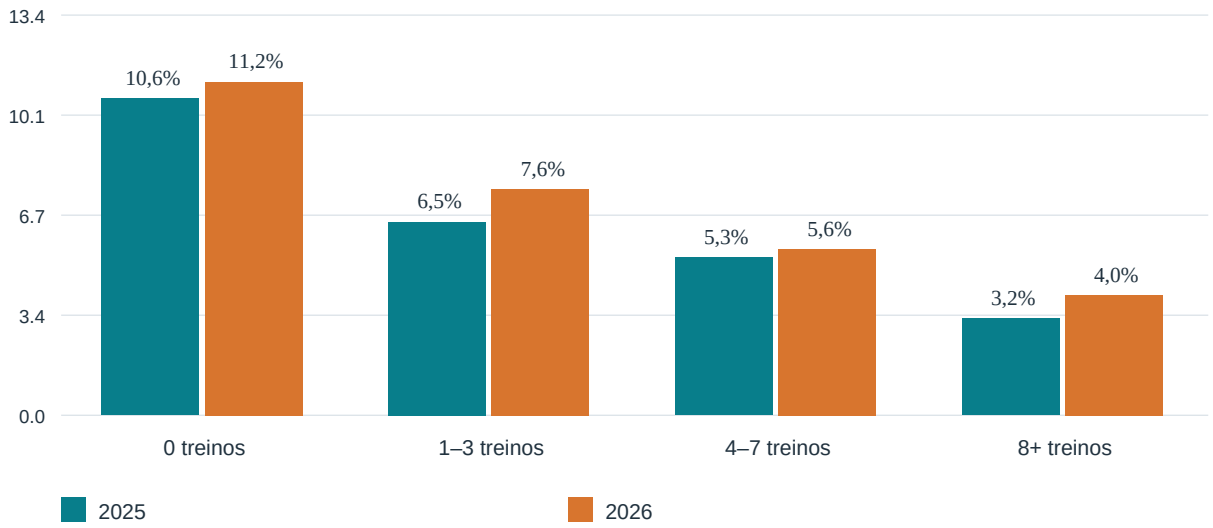

2025: fevereiro–dezembro; janeiro não tem uso de dezembro/2024 disponível. 2026: janeiro–setembro. A tabela abaixo separa os planos em 2026.

Plano	Treinos no mês anterior	Exposições	Perdas	Churn
anual	0 treinos	17.769	1.562	8,79%
anual	1–3 treinos	19.968	610	3,05%
anual	4–7 treinos	10.941	91	0,83%
anual	8+ treinos	18.697	74	0,40%
mensal	0 treinos	1.438	586	40,75%
mensal	1–3 treinos	16.167	2.133	13,19%
mensal	4–7 treinos	11.581	1.165	10,06%
mensal	8+ treinos	19.689	1.475	7,49%

O gradiente permanece dentro dos dois planos. Ainda é necessário controlar tempo de assinatura, calendário de renovação e perfil. As taxas são históricas de grupos; não são probabilidades individuais nem demonstram que aumentar treinos causa retenção.

No corte atual, 1.702 pagantes não registraram treino válido em setembro e 1.148 tinham menos de 30 dias de assinatura. São populações distintas; as janelas de uso precisam ser interpretadas junto ao tempo de exposição.

4. Hipóteses e limites do diagnóstico

Hipótese	Evidência	Próxima verificação
Baixo engajamento antecede saída	Gradiente por uso anterior persiste dentro dos planos.	Comparar coortes, tempo de casa e elegibilidade de renovação.
Reajuste contribuiu para churn mensal	10,07% em jan–fev; 12,82% em mar–abr; 10,34% em mai–set/2026.	Separar sazonalidade, mudanças de perfil e ciclos; comparação entre períodos não basta.
Problema técnico afetou retenção	Tickets técnicos aumentam de 19 em abril para 383 em maio e 310 em junho.	Ligar abertura anterior à saída e tema do ticket. Não presumir versão histórica do app.
Canal indica fricções ou públicos diferentes	Taxas de canal distintas em 2026.	Separar plano, perfil e saída por falha de pagamento.

Fontes de uso não conciliadas: 6.716 linhas de setembro diferem entre BI e atividade tratada, incluindo 5.542 pagantes atuais. A diferença não foi atribuída apenas a duplicatas. O histórico identifica a fonte BI; as variáveis recomendadas para clusterização usam a atividade tratada e duas janelas iguais de 30 dias para medir tendência.

Renovação automática: cinco divergências conhecidas entre eventos e retrato; em 1.112 ativos os eventos relevantes não informam o estado inicial. Os campos ficam separados, com ausências e sinalização, e fora dos candidatos ao agrupamento.

Viés da pesquisa: cancelamento no site e resposta opcional limitam a representatividade. Renovação desligada não equivale a perda de assinatura. Associação de uso, preço ou suporte com churn não identifica, isoladamente, causa.

Valor: a última cobrança aprovada, dividida por 12 no anual, é uma aproximação mensal descritiva. Não é receita contábil, LTV nem retorno de retenção. Estornos, chargebacks, ofertas e custo de servir precisam de tratamento próprio.

5. Método, validação e encaminhamento

Reconstrução temporal. Eventos fornecem início e expiração. Assinaturas anteriores a 01/07/2024 usam o início do retrato como semente. A base atual contém uma assinatura por conta, sem troca de plano/canal nos eventos; essas condições são verificadas. Contas de teste são excluídas pelo e-mail normalizado.

Tratamento. Horários são convertidos para Brasília e limitados a 30/09/2026. Foram removidas 9.383 cópias de treinos do relógio no app. Duração inválida fica marcada e fora dos agregados válidos; 999 distâncias incompatíveis e três altas sem avaliação por ritmo ficam nulas. A regra não altera os arquivos originais.

Cobertura. Em 2025, ausência de linha no BI é tratada como zero treino somente dentro da cobertura e população definidas. Sessões do app ausentes nos meses sem treino de 2025 continuam ausentes. Janeiro/2025 não recebe uso anterior inventado.

Validação. Fechamento nas âncoras oficiais, soma por plano/canal, três assinantes e três expirações confrontados com o retrato, testes das regras temporais e hashes dos 11 arquivos brutos utilizados antes e depois. Dados individuais e amostras ficam fora do Git.

Frente	Material de apoio
Leonardo	Base por pagante, 17 variáveis candidatas e dicionário; selecionar, tratar ausências e validar os grupos.
Claudinne	Filtros, auditoria por coluna, alertas e decisões de tratamento.
Kiril	Diagnóstico e hipóteses; personas dependem dos clusters e de evidências observadas.
Marcela	Plano, canal, indicadores e aproximações financeiras identificadas; completar custos e valor.
John	Síntese editável, método, tabelas, gráficos e roteiro de estudo para integrar o relatório.

Rastreabilidade: docs/enunciado.md; docs/dicionario_dados.md; decisoes.md; src/preparar_diagnostico_s5.py. Tabelas e textos completos em saidas/s5_john/. Bases individuais e manifesto em dados/processados/s5_john/.

Pendente do grupo: clusters, personas e priorização final. Para medir churn por cluster, aplicar a segmentação a observações históricas compatíveis; grupos feitos só com sobreviventes no corte não identificam diretamente os perfis de quem já saiu.